

# Statistiques descriptives

**Exemple.** On lance un dé cubique 40 fois, et on note le résultat dans ce tableau

|          |   |    |   |   |   |    |
|----------|---|----|---|---|---|----|
| Valeur   | 1 | 2  | 3 | 4 | 5 | 6  |
| Effectif | 5 | 10 | 5 | 7 | 3 | 10 |

**Définition.** La moyenne d'une série statistique de  $N$  valeurs  $x_1; x_2; \dots; x_N$  est

$$m = \frac{x_1 + x_2 + \dots + x_N}{N}$$

**Définition.** La moyenne pondérée d'une série statistique de valeurs  $x_1; x_2; \dots; x_N$  de poids (ou effectifs) respectifs  $c_1; c_2; \dots; c_N$  est

$$m = \frac{c_1 x_1 + c_2 x_2 + \dots + c_N x_N}{c_1 + c_2 + \dots + c_N}$$

**Exemple.** Dans l'exemple initial,  $m = \frac{5 \times 1 + 10 \times 2 + 5 \times 3 + 7 \times 4 + 3 \times 5 + 10 \times 6}{40} = 3,575$

**Propriété. Linéarité.** Soit  $a$  et  $b$  deux nombres réels et  $x_1, x_2, \dots, x_N$  une série statistique de moyenne  $m$ .

La moyenne de la série  $ax_1; ax_2; \dots; ax_N$  est  $a \times m$ .

La moyenne de la série  $x_1 + b; x_2 + b; \dots; x_N + b$  est  $m + b$ .

**Définition.** L'écart-type d'une série statistique de valeurs  $x_1; x_2; \dots; x_N$  est

$$\sigma = \sqrt{\frac{(x_1 - m)^2 + (x_2 - m)^2 + \dots + (x_N - m)^2}{N}}$$

**Définition.** L'écart-type pondéré d'une série de valeurs  $x_1; x_2; \dots; x_N$  de poids respectifs  $c_1; c_2; \dots; c_N$  est

$$\sigma = \sqrt{\frac{c_1 (x_1 - m)^2 + c_2 (x_2 - m)^2 + \dots + c_N (x_N - m)^2}{c_1 + c_2 + \dots + c_N}}$$

**Remarque.** L'écart-type d'une série statistique est un indicateur de dispersion autour de la moyenne. Plus l'écart-type d'une série est petit, plus les valeurs de la série sont concentrées autour de la moyenne.

**Exemple.**  $\sigma = \sqrt{\frac{5 \times (1 - 3,575)^2 + 10 \times (2 - 3,575)^2 + 5 \times (3 - 3,575)^2 + 7 \times (4 - 3,575)^2 + 3 \times (5 - 3,575)^2 + 10 \times (6 - 3,575)^2}{40}} \approx 1,46$

**Définition.** La médiane  $M_e$  d'une série est la plus petite valeur telle qu'au moins la moitié des valeurs sont  $\leq$

**Idée.** Après tri, la médiane est la valeur qui sépare la série en deux parties de même taille (ou presque).

Par exemple, le salaire médian est le plus petit salaire tel qu'au moins la moitié des salaires sont  $\leq$ .

Si on choisit un salarié au hasard, il y a 50% de chance que le salaire soit  $\leq$  au salaire médian.

**Exemple.** Dans l'exemple initial, la médiane est  $M_e = 3$ , car la moitié des valeurs 1; 2; 3 sont  $\leq 3$ .

**Définition.** Le quartile  $Q_1$  d'une série est la plus petite valeur telle qu'au moins 25 % des valeurs sont  $\leq$

**Définition.** Le quartile  $Q_2$  d'une série est la plus petite valeur telle qu'au moins 50 % des valeurs sont  $\leq$

**Définition.** Le quartile  $Q_3$  d'une série est la plus petite valeur telle qu'au moins 75 % des valeurs sont  $\leq$

**Définition.** L'écart interquartile d'une série statistique est  $Q_3 - Q_1$ . Il s'agit d'un indicateur de dispersion.

**Exemple.** On considère la série ordonnée des 9 valeurs suivantes : 1; 3; 7; 8; 10; 11; 12; 12; 58.

Alors  $0,25 \times 9 = 2,25 < 3$ . Donc  $Q_1$  est la 3<sup>ème</sup> valeur.  $0,75 \times 9 = 6,75 < 7$ . Donc  $Q_3$  est la 7<sup>ème</sup> valeur.

Plus de 25 % des valeurs

1; 3; 7; 8; 10; 11; 12; 12; 58 donc  $Q_1 = 7$

Moins de 25 % des valeurs

Plus de 75 % des valeurs

1; 3; 7; 8; 10; 11; 12; 12; 58 donc  $Q_3 = 12$

Moins de 75 % des valeurs

L'écart interquartile est donc  $Q_3 - Q_1 = 12 - 7 = 5$ .

**Définition. Le  $k$ -ème décile** ( $k \in \{1; 2; \dots; 9\}$ ) d'une série est la plus petite valeur telle qu'au moins  $\frac{k}{10}$  des valeurs sont  $\leq$ .

**Définition. Le  $k$ -ème percentile** ( $k \in \{1; 2; \dots; 99\}$ ) d'une série statistique est la plus petite valeur telle qu'au moins  $k$  % des valeurs sont  $\leq$ .